# UJIAN AKHIR SEMESTER LAPORAN BIG DATA

## (CLASSIFICATION REGRESSION)



### Disusun oleh:

Ravino Rahman 2018420009

Muhammad Hafizh Azzasafah 2018420017

Febrian Dimas Winaputra 2018420064

UNIVERSITAS DR. SOETOMO SURABAYA

TAHUN AJARAN 2021-2022

## Jenis Soal: Classification

Dataset: Starbucks Customer Survey

Link dataset: link dataset starbuck

Tujuan: untuk mensurvei perilaku customer pada pelaku bisnis (starbucks).

Manfaat: Kegiatan survei customer ini dapat memprediksi perilaku customer pada suatu bisnis. sehingga perilaku usaha dapat melakukan strategi untuk kedepannya.

1. Lakukan load dan read data ke dalam format dataframe, tampilkan hasilnya.

```
# Load and read data ke dalam format dataframe
csv = spark.read.csv('dataset/customers.csv',inferSchema=True, header=True)
csv.show(5)
```

#### Hasil Output:

```
Setting default log level to "NARM".

To adjust logging level use sc. settoglevel(newLevel). For sparkR, use settoglevel(newLevel).

22/09/07 22:27:24 WARM package: Truncated the string representation of a plan since it was too large. This behavior can be adjusted by setting 'spark.sql.debug.maxToStringFields'.

| Id|gender|age|status|income|visitNo|method||timeSpend|location|membershipCand||itemPurchaseCoffee||tempurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePastries||temPurchasePas
```

- 2. Lakukan pre-processing data yang meliputi:
  - a) Pemilihan fitur/atribut yang menunjang dari tujuan klasifikasi.

```
# Data Preprocessing - Drop Columns

dropColumns = ['itemPurchaseCoffee','itempurchaseCold','itemPurchasePastries','itemPurchaseJuices','itemPurchaseSandwiches',

'itemPurchaseOthers','spendPurchase','productRate','priceRate','promoRate','ambianceRate','wifiRate','serviceRate',

'chooseRate','promoMethodApp','promoMethodSoc','promoMethodEmail','promoMethodDeal','promoMethodFriend','promoMethodDisplay',

'promoMethodBillboard','promoMethodOthers','loyal']
```

Pada pemilihan ini kolom data yang dihilangkan yaitu:

itemPurchaseCoffee','itempurchaseCold','itemPurchasePastries','itemPurchaseJuices'
,'itemPurchaseSandwiches','itemPurchaseOthers','spendPurchase','productRate','pric

eRate', 'promoRate', 'ambianceRate', 'wifiRate', 'serviceRate', 'chooseRate', 'promoMethod dApp', 'promoMethodSoc', 'promoMethodEmail', 'promoMethodDeal', 'promoMethodDisplay', 'promoMethodBillboard', 'promoMethodOthers', 'loyal'

b) Penanganan missing value pada data yang hilang. Jelaskan cara apa yang digunakan untuk menangani data yang hilang (dengan menghapus row, atau mengisi data yang hilang dengan metode statistik tertentu).

```
# Hasil Data setelah drop kolom
csv.show(5)
# Hasil Atribut untuk diklasifikasi
csv.printSchema()

# Data Preprocessing - Drop Duplicates
csv.dropDuplicates().show(5)

# Data Preprocessing - Handle missing data
csv.fillna('0')
csv.na.drop().show(5)
```

Dalam menangani missing value menggunakan function *fillna()* dengan nilai 0.

c) Penanganan data yang duplikasi, tampilkan data yang terduplikasi dan hasil setelah penanganan.

Data yang terduplikasi:

```
Id|gender|age|status|income|visitNo|method|timeSpend|location|membershipCard|
                                                                                   0
  40
               2
                              2
                                              2
                                                         0
                                                                   0
          0
               1
                      2
                              0
                                       2
                                              0
                                                         1
                                                                   2
                                                                                   0
                                                                                   1
               1
                      2
                              0
                                       3
                                              2
                                                         0
                                                                   0
  85
          0
               1
                      2
                              1
                                       3
                                              0
                                                         2
                                                                   2
                                                                                   1
 118
               зĺ
                                       2|
                                              0 l
                                                         2
only showing top 5 rows
Data yang sudah didrop duplicates : 113
```

Hasil setelah penanganan:

```
Id|gender|age|status|income|visitNo|method|timeSpend|location|membershipCard
                                                                               0
                                                                               0
   2
          1
              1
                     0
                            0
                                     3
                                            2
                                                       0
                                                                1
   3
          0
              1
                     2
                             0
                                     2
                                            0
                                                       1
                                                                2
                                                                               0
          1
              1
                     0
                             0
                                     3
                                            2
                                                                2
                                                       0
   5
          0
              1
                     0
                            0
                                     2
                                            2
                                                       1
                                                                1
only showing top 5 rows
Data yang sudah dihandle missing data: 113
```

3. Tentukan data yang digunakan sebagai data training dan data testing, masukkan ke dalam sebuah variabel.

```
# Membagi data 70% untuk data training, 30 % untuk data testing
dividedData = csv.randomSplit([0.7, 0.3])
trainingData = dividedData[0] #index 0 = data training
testingData = dividedData[1] #index 1 = data testing
train_rows = trainingData.count()
test_rows = testingData.count()
print ("Training data rows:", train_rows, "; Testing data rows:", test_rows)
```

Membagi data training 70% dan data testing 30%.

Hasil output:

```
Id|gender|age|status|income|visitNo|method|timeSpend|location|membershipCard|
          1
              1
                      0
                             01
                                      3|
                                             0 l
                                                        1
                                                                 0 l
                                                                                 01
          1
              1
                      0
                             01
                                      3
                                             2
                                                        0
                                                                 1
                                                                                 0
   2
                                             0
                                                                                 0
   3
          0
              1
                      2
                             0
                                      2
                                                        1
                                                                 2
                      0
                                      3
                                             2
                                                        0
                                                                 2
   4
          1
              1
                             0
   5
                                      2
                                                        1
          0|
                      0
                             0
                                             2
only showing top 5 rows
Training data rows: 83; Testing data rows: 30
```

4. Lakukan pemodelan dengan metode klasifikasi yang digunakan.

```
# 4 Inisialisasi klasifikasi dengan metode regresi
classifier = LogisticRegression(
    labelCol="label",featuresCol="features",maxIter=10,regParam=0.3)
# uji data klasifikasi
model = classifier.fit(trainingDataFinal)
print ("Classifier model is trained!")
```

Menggunakan metode regresi dengan function LogisticRegression().

Hasil output:

```
Classifier model is trained!
```

Melakukan pengelompokan data training hasil data test.

```
#Inisialisasi Penggabungan data
assembler = VectorAssembler(inputCols = [
    "gender", "age", "status", "income","Id",
    "timeSpend","location","membershipCard"], outputCol="features")
trainingDataFinal = assembler.transform(
    trainingData).select(col("features"), col("visitNo").alias("label"))
trainingDataFinal.show(truncate=False, n=2)
```

Hasil output:

5. Lakukan prediksi hasil data test.

```
# 5 Prediksi data testing
prediction = model.transform(testingDataFinal)
predictionFinal = prediction.select(
    "features", "prediction", "probability", "trueLabel")
predictionFinal.show(truncate=False, n=3)
prediction.show(truncate=False, n=3)
```

## Hasil output:

```
| trueLabel | true
```

6. Hitung evaluasi performance dari hasil prediksi.

```
# 6 Hitung performa model
correctPrediction = predictionFinal.filter(
    predictionFinal['prediction'] == predictionFinal['trueLabel']).count()
totalData = predictionFinal.count()
print("correct prediction:", correctPrediction, ", total data:", totalData,
    ", accuracy:", correctPrediction/totalData)
```

## Hasil output: